

بناء نموذج لغوي متعدد الوسائط للذكاء الاصطناعي الجيومكاني OmniGeo

مقدمة

يقدم هذا المشروع نموذج OmniGeo، وهو نموذج لغوي كبير متعدد الوسائط مصمم خصيصاً لمجال الذكاء الاصطناعي الجيومكاني. يهدف الابتكار إلى دمج أنواع متباينة من البيانات مثل صور الأقمار الصناعية، وخرائط الشوارع، والنصوص الجغرافية، والمعلومات المتجهة ضمن إطار عمل موحد. يستطيع النموذج معالجة خمس مهام أساسية تشمل التنبؤ الصحي، وتصنيف الوظائف الحضرية، وتحليل صور الاستشعار عن بعد، والإدراك البصري للمدن، واستخراج الدلالات المكانية. نريد ان نثبت النتائج أن OmniGeo يتفوق على النماذج المتخصصة والتقليدية من خلال قدرته الفائقة على الاستدلال المكاني وفهم التعليمات المعقدة. يعتمد النجاح التقني للمشروع على بناء مجموعة بيانات ضخمة للضبط الدقيق وربط المعرفة اللغوية العميقة بالخصائص الجغرافية للعالم الحقيقي. يعد هذا العمل خطوة رائدة نحو تطوير نماذج أساس شاملة قادرة على حل التحديات الجيومكانية المتعددة بكفاءة عالية.

اهداف المشروع

تطوير نظام ذكاء اصطناعي جغرافي متكامل يمكنه فهم العالم الجغرافي من خلال دمج الرؤية الحاسوبية وفهم اللغة الطبيعية، مما يفتح آفاقاً جديدة للتطبيقات الحضرية والبيئية والصحية.

الهدف	التفاصيل
دمج البيانات الجغرافية متعددة الوسائط	تمكين النموذج من معالجة النصوص، الصور، والبيانات المكانية في نموذج واحد
تغطية المهام الأساسية الخمس في GeoAI	الجغرافيا الصحية، الجغرافيا الحضرية، الاستشعار عن بعد، الإدراك الحصري، الدلالات الجغرافية
بناء مجموعة بيانات تعليمية	إنشاء 12 مجموعة بيانات تعليمية متعددة الوسائط لـ GeoAI
تحسين اتباع التعليمات	تعزيز قدرة النموذج على فهم وتنفيذ التعليمات الجغرافية المحددة
استخراج المعرفة الجغرافية الضمنية	استغلال المعرفة الجغرافية المضمنة في نماذج اللغة الأساسية أثناء التدريب المسبق
تحقيق أداء تنافسي	التفوق على النماذج المخصصة للمهام ونماذج LLM الموجودة على مهام جغرافية متنوعة
تمكين التعلم بدون أمثلة (Zero-Shot)	تحقيق نتائج تنافسية في المهام الجغرافية دون تدريب مسبق خاص
تسهيل نقل المعرفة الجغرافية	تمكين المشاركة والنقل عبر الوسائط والمهام الجغرافية المختلفة

مراحل تنفيذ المشروع

المرحلة الأولى (جمع البيانات)

1. المحاذاة المكانية:

تأكد من أن جميع البيانات (الصحية، العمرانية، وصور الأقمار الصناعية) تغطي نفس النطاق الجغرافي (مثلاً محافظة القاهرة). يتم الاعتماد على البيانات الصحية المصرية. نوع البيانات: سلاسل زمنية لوفيات أمراض معينة (مثل الزهايمر أو أمراض الجهاز التنفسي) موزعة حسب المحافظات أو المراكز.

الرابط: [بوابة مصر لبيانات التغطية العامة والإحصاء](#)

2. جغرافيا المدن (تصنيف وظائف المناطق الحضرية):

الرابط: [الهيئة العامة للتخطيط العمراني](#) أو [بيانات OpenStreetMap لمصر](#).

- **تحويل المتجهات لنصوص:** تحويل إحصائيات CAPMAS وبيانات POI من OpenStreetMap إلى فقرات نصية باللغة العربية أو الإنجليزية (حسب لغة التدريب المختارة) للمناطق المصرية (القاهرة، الإسكندرية، إلخ). خرائط التخطيط العمراني: الهيئة العامة للتخطيط العمراني (GOPP) في مصر، للحصول على تصنيفات الأراضي (سكني، تجاري، صناعي). [الرابط: الهيئة العامة للتخطيط العمراني](#) أو [بيانات OpenStreetMap لمصر](#).
- **توليد التوصيفات (Captions):** استخدام نموذج مثل InstructBLIP لإنشاء وصف نصي لصور الأقمار الصناعية الخاصة بالمناطق المصرية (مثل وصف منطقة "مصر الجديدة" أو "المنطقة الصناعية بـ 6 أكتوبر") لتعزيز الفهم الدلالي للنموذج.

3. الاستشعار عن بعد (تصنيف الصور الجوية)

بالنسبة لمصر:

- **صور الأقمار الصناعية:** يمكن استخدام NASA Earthdata للحصول على صور WorldView لمصر، أو الاعتماد على صور قمر EgyptSat (إذا توفرت للباحثين)، أو صور Sentinel-2 المجانية من وكالة الفضاء الأوروبية.
- [الرابط: NASA Earthdata - WorldView](#) أو [ESA Copernicus Hub](#).

4. الإدراك الحصري (Perception)

- **المصدر:** Google Street View هو المصدر الأفضل للمدن الكبرى في مصر (مثل القاهرة والجيزة والإسكندرية).
- **التطبيق:** يتم استخراج صور الشوارع للمناطق المصرية المستهدفة لتقييم معايير مثل (الضوضاء، الجمال، الحيوية) كما فعل النموذج الأصلي [Google Maps Street View].

5. الدلالات الجغرافية (التعرف على أسماء الأماكن بمصر)

- **المصدر:** جمع بيانات نصية من تويتر (X) أو الصحف المحلية المصرية (مثل الأهرام أو المصري اليوم) باستخدام كلمات مفتاحية جغرافية مصرية.

- **نوع البيانات:** تغريدات أو أخبار تحتوي على أوصاف لمواقع مصرية (مثل: "حادث عند تقاطع شارع عباس العقاد مع ذاكر حسين") لتدريب النموذج على التعرف على "وصف الموقع" (Location Description) في السياق المصري.

المرحلة الثانية: معالجة البيانات وبناء التعليمات (Data Construction)

هذه الخطوة هي الأهم لربط البيانات النصية بالصور الجغرافية:

1. **معالجة الصور:**
 - قص صور الاستشعار عن بعد (RS) من WorldView حسب المناطق الجغرافية المعنية.
 - توليد التوصيفات (Captions): استخدام نموذج InstructBLIP لإنشاء وصف نصي تفصيلي لكل صورة (سواء صور الأقمار الصناعية أو صور الشوارع) لتعزيز الفهم الدلالي.
2. **تحويل البيانات المتجهة إلى نص:**
 - تحويل إحصائيات الوفيات التاريخية إلى فقرات نصية.
 - تحويل بيانات نقاط الاهتمام (POI) إلى نصوص تعتمد على التكرار (Frequency-based text) لتمكين النموذج اللغوي من فهمها.
3. **المحاذاة (Alignment):** دمج الصور مع التوصيفات النصية والبيانات الإحصائية المقابلة لها لتشكيل "بيانات ضبط دقيق متعددة الوسائط" (Multimodal Instruction Data).

المرحلة الثالثة: التدريب (Model Training)

يتم التدريب وفقاً لإطار عمل موحد يدمج المهام الخمس:

1. **الهيكليّة:** استخدام محول (Adaptor) من نوع MLP لربط المشفر البصري (Vision Encoder) بالنموذج اللغوي الكبير.
2. **أساليب التدريب:**
 - يمكن استخدام الضبط الدقيق الكامل (Full Fine-tuning) أو تقنية LoRA (Low-Rank Adaptation) لتقليل استهلاك الموارد.
3. **إعدادات الأجهزة (Hardware):**
 - لنسخة LLaVA: تحتاج إلى 8 وحدات معالجة رسومية من نوع A6000 (بذاكرة 48 جيجابايت لكل منها).
 - لنسخة Qwen2: تحتاج إلى 4 وحدات من نوع L20.
4. **المعاملات:** التدريب لمدة 3 إلى 5 دورات (Epochs)، مع معدل تعلم يتراوح بين $1e-5$ و $2e-6$.

المرحلة الرابعة: التقييم (Evaluation)

يتم تقييم النموذج باستخدام مقاييس تختلف باختلاف المهمة:

- **المهام التنبؤية (مثل الوفيات):** استخدام مقاييس MAE و MSE و R2-score.
- **مهام التصنيف:** استخدام مقاييس الدقة (Precision) والاستدعاء (Recall) و Weighted-F1.